

Efficient Mirror Detection via Multi-level Heterogeneous Learning



The Association for the Advancement of Artificial Intelligence(AAAI) 2023

Ruozhen He, Jiaying Lin, Rynson W.H. Lau

Kyungmin Kim
Chung-Ang University
kyungddin@cau.ac.kr
Aug. 7th 2025



Efficient Mirror Detection via Multi-level Heterogeneous Learning

효율적인 거울 탐지 (CNN의) 단계별로 다른 방식의 학습을 통해



CNN의 각 Level마다 서로 다른 방식의 학습을 통해 효율적으로 거울을 탐지

Intro

- 논문을 선택한 이유
 - 연구주제와 관련된 논문 선정 (거울탐지, 머신러닝/딥러닝)
 - 자주 인용되는 논문 (2023년 논문이며 37회 인용)
 - LiDAR 하드웨어 및 알고리즘 논문이 아닌
새로운 주제의 논문을 읽고 싶었기 때문

Abstract

- 논문의 목표

- 거울 탐지 CNN인



HetNet(Multi-level Heterogeneous Network)을 제시

- 왜 HetNet인가?

- 거울 탐지 Network는 Performance와 Efficiency의 Trade-Off가 존재
- 기존의 Network들은 Performance가 우수하나 Efficiency가 떨어져 실시간 적용에 부적합

- 어떻게 HetNet이 다른가?

- 기존의 Network들은 각 Level별로 같은 Module 적용 (Homogeneous)
- Hetnet은 각 Level별로 다른 Module 적용 (Heterogeneous)






Why HetNet is Important?


I: Introduction

Introduction: Mirror Detection Network

- LiDAR와 마찬가지로 CV(Computer Vision)도 **거울의 반사에 취약함**
 - 로봇이나 드론의 Navigation에 장애를 일으킬 수 있음
- 2019년 이후로 거울 탐지에 관한 Network들이 등장하기 시작
 - MirrorNet (2019)
 - PMD (2020)
 - SANet (2022)



OMG! Mirror!



Introduction: Mirror Detection Network


- 이들은 모두 실험에서 뛰어난 성능을 보여줌
그러나 Computation Cost가 매우 커서 Real-Time 적용이 어려움



- Computation Cost가 큰 이유
 - Low-Level과 High-Level에 모두 같은 Module을 적용
(Homogeneous Structure)
 - Post-Processing Algorithm에 강하게 의존
(추가적인 비용 발생)

Low Level
: 해상도는 크고, 채널은 작음


High Level
: 해상도는 작고, 채널은 큼




**Level마다 같은 Module을
적용하면 비효율적임!**

Introduction: Mirror Detection Network

- 비유를 하자면..
 - High Level의 2x2 Conv 필터를 Low Level에 적용시키는 것은 Cost가 클 수 밖에 없다..!



High Level




Low Level

Introduction: Graph

성능 비교 그래프

Y축
F-Measure
(성능 지표)

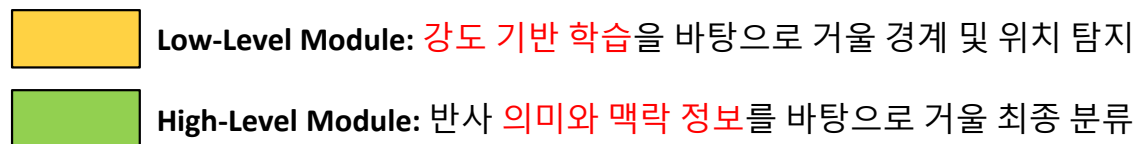



[모델종류]
Mirror는 거울탐지
SOD는 객체탐지

연산량이 많고
FPS가 낮다


1 Gmac
= 10억번의 곱셈/덧셈

Introduction: Network Structure



Introduction: Network Structure

- 각 Network Structure 간단 요약







MirrorNet과 PMD Network의 경우
각 Level별로 동일한 모델을 사용

(피드백 방식만 약간 다름)

Introduction: Network Structure





- 각 Network Structure 간단 요약



SANet의 경우
모든 Level을 통합하여 학습

Introduction: Network Structure


- 각 Network Structure 간단 요약



HetNet의 경우
각 Level별 모듈이 다름

Introduction: Mimic Brain



- HetNet은 인간 시각 처리 과정을 모방
 1. 망막의 세포는 빛 신호를 전기 신호로 변환
 2. 전기 신호가 시각 피질로 전달되어 추가적인 정보 처리, 통합, 추상화
 3. 결과적으로 시각이 형성



Introduction: Mimic Brain

- HetNet은 인간 시각 처리 과정을 모방

1. 물체가 가진 빛이
망막세포를 거침



2. 빛 신호가
전기 신호로 변환


3. 시각피질에서 추상화를 거쳐
푸앙이라는 시각정보를 얻어냄



Introduction: Mimic Brain


- 뇌가 반사를 탐지하는 과정

1. 망막이 **Low Level Information (밝기 대비, 색상)**을 얻어냄
2. 시각피질에서 윤곽선, 형태와 같은 **추상화**를 거침
3. 이를 통해 생성된 유사성, 맥락적 대비 같은 **High Level 정보**로 반사 여부를 판단



Introduction: HetNet Structure


- HetNet Structure 특징 2가지
 - Heterogeneous Module
 - No Post-Processing
- 이를 기반으로 연산량은 72.73% 감소, 속도는 664% 증가



Introduction: HetNet Structure 1

- Heterogeneous Module


- Network의 Shallow Stage와 Deep Stage에 각기 다른 Module 적용
- Shallow에는 MIC Module을 통해 Low Level Feature로부터 거울 위치 추정
- Deep에는 RSL Module을 통해 High Level Feature로부터 맥락과 의미 정보 획득



Introduction: HetNet Structure 2


Post-Processing Algorithm

- 기존 Mirror Detection Network는 High-Level Information에 크게 의존하기에 **후처리 필요**
- 그러나 HetNet의 경우에는 Heterogeneous Module Structure로 인해 **따로 후처리 알고리즘이 필요하지 않음**



[기존 Network]
Output을
Post-Processing
해줘야 함!

VS



[HetNet]
후처리가 따로
없기에
Cost가 훨씬 적음

	Post - Processing
사용 시점	출력 후
병렬성	병렬 처리 어려움
속도	느림 (이미지 클수록)
실시간성	낮음





How to Construct HetNet?

II: Methodology

Methodology

Methodology 4 Step

- Overall Structure
- MIC Module
- RSL Module
- Loss Function





Overall Structure

Methodology

- Methodology 4 Step

- Overall Structure
- MIC Module
- RSL Module
- Loss Function




Overall Structure

Methodology: Overall Structure


- Overall Structure Step 1

ResNeXt101
: 기존의 ResNet을 병렬 처리한
CNN



Methodology: Overall Structure

Overall Structure Step 2



각 Stage별 Module 배치


- Stage 1~3: **MIC** (Low Level Module)
- Stage 4~5: **RSL** (High Level Module)
- Stage 6: **GE** (Global Extractor)

Global Extractor

ResNeXt 구조에
Attention-like 구조를 삽입하여
각 Stage에 중요도 부여

Methodology: Overall Structure

Overall Structure Step 3




Output간의 Fusion & Aggregation


- 각 Level 단위에서 Fusion 진행
- Cross Aggregation으로 두 Level을 합치기

Methodology: Overall Structure

Overall Structure Step 3



[Fusion]



[Cross Aggregation]

Fusion

- 두 Output을 Multiplication
- 3x3 Conv 연산 2회 수행 (with BatchNorm ReLU)



Cross Aggregation

- High Level Output의 경우 Upsampling,
Low Level Output의 경우 Conv 연산 후 Fusion

Methodology

- Methodology 4 Step


- Overall Structure
- MIC Module
- RSL Module
- Loss Function



Overall Structure


Methodology: The MIC Module (Low Level)

- MIC Module은 **게슈탈트 심리학**으로부터 출발
 1. 사람들은 전체를 먼저 본 뒤, 그 후 일부를 본다
 2. 사람은 장면 전체를 볼 때 여러 요소의 연결을 중요하게 생각 (e.g. 모양, 위치, 크기, 색상)
- 이를 기반으로, **같은 풍경을 다른 방향에서 본다면**
특정 물체의 특징을 더 뚜렷하게 얻어낼 수 있음
- 시각 피질의 **방향 선택성 선호 세포**를 모방한
ICFE(Intensity-based **C**ontrasted **F**eature **E**xtractors)를 사용해
한 방향의 특징 학습을 진행
 - 쉽게 말해 특정 방향에서의 특징을 학습하는 모듈을 착안해냄



Methodology: The MIC Module (Low Level)

- MIC (Multi-orientation Intensity-based Contrasted) Module은 두 개의 ICFE의 병렬 구조
 - 목표는 거울의 위치를 대략적으로 찾아내는 것
 - 두 방향의 정보를 병렬 처리하기에 계산 비용도 감소
- MIC Module을 이용해 두 방향에서의 저수준 대비를 집중해서 분석함
 - 저수준 대비는 밝기나 색깔 같은 기본적인 시각적 차이
 - 이를 기반으로 거울의 위치를 특정한다




MIC Module Structure

Methodology: The MIC Module (Low Level)

- MIC Module Learning 1


- Input Feature가 주어지면 하나는 그대로 ICFE에,
다른 하나는 90도 회전 후 또 다른 ICFE에 넣어준다



Methodology: The MIC Module (Low Level)


■ MIC Module Learning 2

- 각 ICFE에서는 Pooling과 Conv연산이 진행된 후 Output이 나온다
- 회전된 Input의 경우 회전을 복원한 후 두 Output을 **Concatenate**해준다



Methodology: The MIC Module (Low Level)



- MIC Module Learning 3
 - 추가적인 Convolution 연산을 통해 최종 Output을 얻어준다



Methodology

- Methodology 4 Step

- Overall Structure
- MIC Module
- RSL Module
- Loss Function



Overall Structure

Methodology: The RSL Module (High Level)

- 그러나 저수준 대비 (Low Level Information)만으로는 거울 탐지에 한계가 있으므로 High Level Information (맥락, 유사성 등의 의미 정보)가 필요
- 거울 탐지에 가장 큰 힌트는 불연속성

거울 안은 거울 주위와 다르게
벽이 아닌 다양한 물체가 나타나는
불연속성 발생




Methodology: The RSL Module (High Level)

- RSL(Reflection Semantic Logical) Module

- 하나의 Input Feature로부터 네 개의 Branch를 통해 서로 다른 정보 추출
- 각 Branch의 경우 Convolution Layer와 커널(필터) 사이즈가 다름

- 각 Branch의 경우 Receptive Field로부터 Semantic Feature를 추출

- 이미지의 특정 영역에서 의미를 추출
- 각기 다른 Branch를 나중에 합치므로 Receptive Field가 넓어짐





RSL Module Structure

Methodology

- Methodology 4 Step

- Overall Structure
- MIC Module
- RSL Module
- Loss Function



Overall Structure

Methodology: Loss Function

- Loss Function의 구성
 - 각 픽셀 별 거울 탐지: Pixel Position Aware (**PPA**) Loss
 - 거울의 경계 탐지: Binary Cross Entropy (**BCE**) Loss
- PPA Loss = wBCE Loss + wIoU Loss
- 최종 Loss Function

$$Loss = L_{bce} + \sum_{i=0}^4 \frac{1}{2^i} L_{ppa}^i$$



Is HetNet Useful?

III: Experiments

Experiments: Setting

- **Dataset**

- MSD와 PMD라는 두 종류의 이미지 Dataset

- **Evaluation Metrics**

- Mean Absolute Error (MAE)
- Intersection over Union (IoU)
- F-measure (F-0.3 Score)

- **Hardware**

- RTX2080Ti GPU

Experiments: Comparison to Other Methods

■ 성능 비교 결과

- 10개의 다른 Network들과 Metric 비교 시
모든 Metric에서 **HetNet**이 최고 성능 달성
- 빨간색은 1위, 파란색은 2위

■ FLOPs & FPS

- 거울 탐지 Network 중 가장 우수한 성능을 가짐
- 다만 왜 HetNet만 Input Size가 살짝 작은지는 의문

Method	MSD			PMD		
	MAE↓	IoU↑	F_β ↑	MAE↓	IoU↑	F_β ↑
R ³ Net	0.111	0.554	0.767	0.045	0.496	0.713
CPDNet	0.116	0.576	0.743	0.041	0.600	0.734
EGNet	0.096	0.630	0.779	0.088	0.210	0.590
LDF	0.068	0.729	0.843	0.038	0.633	0.783
MINet	0.088	0.664	0.817	0.038	0.608	0.765
SETR	0.071	0.690	0.851	0.035	0.564	0.797
VST	0.054	0.791	0.871	0.036	0.591	0.736
MirrorNet	0.065	0.790	0.857	0.043	0.585	0.741
PMD	0.047	0.815	0.892	0.032	0.660	0.794
SANet	0.054	0.798	0.877	0.032	0.668	0.795
HetNet	0.043	0.828	0.906	0.029	0.690	0.814

Metric Comparison

Method	Input Size	Para.	FLOPs	FPS
R ³ Net	300×300	56.16	47.53	8.30
CPDNet	352×352	47.85	17.77	65.83
EGNet	256×256	111.64	157.21	10.76
LDF	352×352	25.15	15.51	107.74
MINet	320×320	162.38	87.11	3.55
SETR	480×480	91.76	85.41	2.84
VST	224×224	44.48	23.18	6.05
MirrorNet	384×384	121.77	77.73	7.82
PMD	384×384	147.66	101.54	7.41
SANet	384×384	104.80	66.00	8.53
HetNet	352×352	49.92	27.69	49.23

FLOPs & FPS

Experiments: Comparison to Other Methods

Visual Comparison

- 여러 환경에서
정확한 Segmentation을
이뤄냄




Figure 6: Qualitative comparison of our model with relevant state-of-the-arts in challenging scenarios.

Experiments: Ablation Study

Network 구조 변화 실험

- High Level Module과 Low Level Module을 거꾸로

Low Level Module만

High Level Module만

적용 시, HetNet보다 성능이 떨어짐

Architecture	MAE↓	IoU↑	F_β ↑	Para.	FLOPs	FPS
A_{ba}	0.046	0.821	0.897	50.13	60.89	37.73
A_a	0.049	0.811	0.889	47.58	26.90	43.34
A_b	0.046	0.817	0.897	52.50	61.67	39.00
HetNet	0.043	0.828	0.906	49.92	27.69	49.23

Network Structure Test

Experiments: Ablation Study

Component 점진 적용 실험

- 각 모듈들을 기본 Network에서 점차 늘려나갈 경우 성능이 점진적으로 증가
- Segmentation 정확도도 갈수록 향상

Ablation	Base	GE	ICFes	MICs	RSLs	MAE↓	IoU↑	F_β ↑	Para.	FLOPs	FPS
I	✓					0.056	0.773	0.872	47.53	26.61	60.31
II	✓	✓				0.050	0.805	0.882	47.53	26.68	58.05
III	✓	✓	✓			0.053	0.781	0.878	47.55	26.68	53.87
IV	✓	✓		✓		0.049	0.811	0.892	47.56	26.68	51.45
V	✓	✓			✓	0.049	0.809	0.890	49.92	27.47	54.20
HetNet	✓	✓		✓	✓	0.043	0.828	0.906	49.92	27.69	49.23

							
Input	GT	(I)	(II)	(III)	(IV)	(V)	HetNet

Component Gradually Adding


Experiments: Ablation Study

Rotation Strategy 효율성 실험

- ICFE를 1개에서 4개까지 늘려가며 MIC와 성능을 비교
- ICFE*3은 60도 회전으로 인해 Padding이 필요하므로 성능 감소
- ICFE*4는 ICFE*3보다는 성능이 좋으나 노이즈도 함께 늘어나서 성능이 좋지 않음
- MIC와 ICFE+ICFE의 차이
 - ICFE+ICFE는 방향이 고정
 - MIC는 방향이 시시각각 변화

Strategy	MAE↓	IoU↑	F_β ↑	Para.	FLOPs	FPS
ICFE	0.049	0.802	0.887	49.92	27.68	49.52
ICFE+ICFE	0.048	0.806	0.891	49.92	27.69	45.58
ICFE*3	0.047	0.821	0.895	49.93	27.69	40.73
ICFE*4	0.046	0.820	0.901	49.93	27.70	36.08
MIC	0.043	0.828	0.906	49.92	27.69	49.23

Rotation Strategy Test



ICFE Structure

Conclusions



Thank you!

Questions?